C-Eval 评测报告

结论

- 总体准确率：91.90%（1237/1346）
- 能力判断：很强
- 无效答案：6，请求错误：0
- 平均响应耗时：1.31s

评测配置

- 模型：glm-5.3
- 接口：http://10.10.92.9:8000/v1/chat/completions
- 数据集：C-Eval val split
- 题目范围：52 个科目，1346 道题
- Prompt：chat few-shot answer-only，shots=5
- temperature：0.0
- max_tokens：16384
- reasoning_effort：high
- workers：4
- 开始时间：2026-09-02 10:10:47
- 结束时间：2026-09-02 10:27:06

总览

项目	总题数	正确数	准确率	无效答案	请求错误	平均耗时
总体	1346	1237	91.90%	6	0	1.31s
C-Eval Hard	152	140	92.11%	1	0	2.95s

分类得分

项目	总题数	正确数	准确率	无效答案	请求错误	平均耗时
Humanities	257	238	92.61%	0	0	0.86s
Other	384	354	92.19%	1	0	1.27s
STEM	430	395	91.86%	2	0	1.79s
Social Science	275	250	90.91%	3	0	1.04s

得分最高科目

项目	总题数	正确数	准确率	无效答案	请求错误	平均耗时
操作系统 (operating_system)	19	19	100.00%	0	0	0.80s
高中物理 (high_school_physics)	19	19	100.00%	0	0	1.27s
初中数学 (middle_school_mathematics)	19	19	100.00%	0	0	1.27s
初中物理 (middle_school_physics)	19	19	100.00%	0	0	0.64s
初中化学 (middle_school_chemistry)	20	20	100.00%	0	0	1.65s
高中地理 (high_school_geography)	19	19	100.00%	0	0	0.77s
思想道德修养与法律基础 (ideological_and_moral_cultivation)	19	19	100.00%	0	0	0.44s
体育学 (sports_science)	19	19	100.00%	0	0	0.46s
植物保护 (plant_protection)	22	22	100.00%	0	0	0.66s
注册消防工程师 (fire_engineer)	31	31	100.00%	0	0	0.87s

得分最低科目

项目	总题数	正确数	准确率	无效答案	请求错误	平均耗时
注册电气工程师 (electrical_engineer)	37	28	75.68%	0	0	1.70s
高中语文 (high_school_chinese)	19	15	78.95%	0	0	1.61s
概率统计 (probability_and_statistics)	18	15	83.33%	0	0	2.27s
注册计量师 (metrology_engineer)	24	20	83.33%	0	0	1.23s
高中数学 (high_school_mathematics)	18	15	83.33%	0	0	3.93s
初中地理 (middle_school_geography)	12	10	83.33%	1	0	0.69s
注册城乡规划师 (urban_and_rural_planner)	46	39	84.78%	0	0	0.94s
工商管理 (business_administration)	33	28	84.85%	0	0	1.26s
大学经济学 (college_economics)	55	47	85.45%	1	0	2.37s
法律职业资格 (legal_professional)	23	20	86.96%	0	0	1.33s

说明

- 四选一随机基线为 25%。
- 当前报告按公开答案的题目直接计分；无效输出和请求错误均计为错误。
- C-Eval 单科题量较少，单科差异需谨慎解读；总体分数更适合判断部署后的稳定能力。